

Formuła Student - Pachołki :)

Piotr Sokołowski, Michał Pałucki

1. Założenia:

- Celem naszego projektu, było zrealizowanie mechanizmu detekcji i klasyfikacji pachołków. Wspomniane metody, miały pozwolić na wykrycie i identyfikację słupków kierunkowych, występujących podczas przejazdu pojazdu autonomicznego klasy Formuła Student.

2. Realizacja projektu:

- W pierwszym etapie realizacji projektu, najtrudniejszy do poskromienia okazał się używany przez nas DataSet - FSO CO. Był on bardzo, bardzo duży (24Gb) przez co jego przygotowywanie zajmowało wyjątkowo dużo czasu i pamięci ram. Początkowe próby, wykonania jakiegokolwiek uczenia, na zdjęciach z pobranego przez nas datasetu, kończyły się fiaskiem przez brak pamięci vRam.

- Udało nam się, poprawić wydajność zużycia pamięci vRam poprzez użycie Garbage Collectora, jednak nie rozwiązało to wszystkich naszych problemów. Finalnie musieliśmy ręcznie wyłączyć zużycie vRam na GPU, gdyż bez tego nie byłoby w stanie nauczyć modelu prawie niczego :((.

- Próbowaliśmy przeprowadzać eksperymenty związane z wykrywaniem boundingBox'ów bezpośrednio na całych zdjęciach, jednak szybko zrozumieliśmy, że jest to zły pomysł. Problem polegał na tym, że dataset był zbyt różnorodny i podejście do wyznaczonego przez nas zadania detekcji poprzez zastosowanie modelu regresyjnego było niewykonalne. Nie byliśmy w stanie wyznaczyć długości outputu jak i również ustalić jego określonej kolejności.

- Postanowiliśmy więc, przygotować naszą sieć "na samych pachołkach" występujących na zdjęciach naszego datasetu. Wybraliśmy fotografie zawierające 10 pachołków, by w jakimkolwiek stopniu ograniczyć ich wielkość ostrość i jakość na zdjęciach. Przeskalowane do jednego rozmiaru pachołki ważyły wciąż 8GB!!.

- Przygotowany model niestety został nauczony wyglądu samych pachołków (bez zbędnej ilości tła), dlatego sama detekcja nie przebiegła już tak pomyślnie. Zastosowane przez nas Vision Transformers nie były w stanie osiągnąć zadowalającej skuteczności.

3. Wyniki i Wnioski:

- Rezultaty, które udało nam się osiągnąć w kwestii klasyfikacji, są bardziej niż zadowalające. Accuracy na poziomie 97% robi wrażenie! Niestety z detekcją jest mówiąc kolokwialnie - lipa totalna. Pociężyć możemy się tym, że w rzeczywistym przypadku, za detekcję pachołków nie jest odpowiedzialna sieć neuronowa.

4. Podsumowanie.

- W trakcie tego semestru, udało nam się znacznie głębiej zrozumieć działanie sieci neuronowych. Wzbogaciliśmy naszą dotychczasową wiedzę zarówno od strony praktycznej jak i teoretycznej. Szczególne wrażenie, zrobił na nas sposób przygotowania prezentacji (wiedza aż z nich kipiała!)

- Interesujące okazało się przedstawienie sposobów na zrozumienie czego tak właściwie nauczyły się poszczególne filtry sieci konwolucyjnej a w konsekwencji ona sama. Metody te, pozwolą w przyszłości zrozumieć nam lepiej jak należy przygotować model, dataset a może nawet jedno i drugie, by osiągać eleganckie rezultaty uczenia.

- Z przeprowadzonych wykładów najbardziej zapadły nam w pamięć slajdy z splotową implementacją przesuwanych okien. Wreszcie rozumiemy jak działają ramki yolo!

W całym kursie uczenia, wyjątkowo wartościowe były dla nas komentarze w dostarczonych notebookach. Na początku wydawały nam się one zdecydowanie zbyt długie. Jednak z perspektywy czasu, musimy przyznać, że przebrnięcie przez nie wszystkie, powoli i dokładnie znacznie zmieniło sposób w jaki postrzegamy sieci neuronowe.